

Projekt	Wprowadzenie do sztucznej inteligencji	2025/2026
AIR	Stamp Detector	Data: 31.01.2026
Semestr V	Imię Nazwisko Nr. Indeksu Michał Michałowicz 159477 Mateusz Rydzak 159394 Łukasz Kałek 159420	

1. Opis rzeczywistego problemu

Przedmiotem projektu jest opracowanie oprogramowania służącego do weryfikacji obecności pieczęci (w programie pieczęci okrągłych) na dokumentach. Rzeczywistym problemem, który projekt rozwiązuje, jest czasochłonność procesu weryfikacji dokumentacji administracji i biznesie. Obecnie pracownicy biurowi muszą często manualnie przeglądać dokumenty w poszukiwaniu pieczętek, co stanowi wąskie gardło procesów administracyjnych.

Głównym celem projektu jest stworzenie systemu, który skutecznie wykryje okrągłą pieczęć na zadanym dokumencie. Efektem końcowym działania programu ma być wskazanie lokalizacji pieczęci oraz określenie prawdopodobieństwa, że wykryty obiekt jest rzeczywiście pieczęcią.

Motywacja Istotność tematu wynika z rosnącej potrzeby automatyzacji procesów administracyjnych w urzędach oraz przedsiębiorstwach. Zastosowanie tego rozwiązania pozwoli na:

- oszczędność czasu: Pracownicy zostaną odciążeni od żmudnego przeglądania dokumentów, mogąc skupić się na zadaniach merytorycznych.
- zwiększenie prędkości: Szybsza obsługa dokumentów przekłada się bezpośrednio na sprawniejsze załatwianie spraw z perspektywy klienta lub petenta.
- Elastyczność zastosowania: Projekt zakłada możliwość douczania modelu na specyficznych zestawach danych, co pozwoli poszczególnym instytucjom na wyspecjalizowanie narzędzia do wykrywania ich własnych pieczęci.

System jako dane wejściowe przyjmuje dokumenty w formacie PDF. Pomiar dokonywany przez algorytm polega na analizie cech wizualnych dokumentu w celu klasyfikacji obszarów jako "pieczęć" lub "tło (nie-pieczęć)". Wynikiem przetwarzania jest informacja binarna o obecności pieczęci wraz z wartością liczbową określającą prawdopodobieństwo poprawności wykrycia.

Temat projektu ściśle łączy się z dziedziną sztucznej inteligencji, a konkretnie z "Computer Vision". Wykorzystuje techniki przetwarzania obrazów oraz algorytmy uczenia maszynowego (w szczególności Object Detection) do rozpoznawania wzorców graficznych (pieczętki).

2. State of the art

2.1. Modele Transformerowe - analiza tekstu za pomocą tej architektury zaczyna się od zamiany słów na liczby (wektory), do których dodawane są znaczniki pozycji, aby model wiedział gdzie znajdują się one w zdaniu. Następnie analizowane są, przy pomocy mechanizmu uwagi (self-attention), związki pomiędzy słowami i przypisywane są im wagi. Pozwala to na zbudowanie wielowymiarowej mapy kontekstu umożliwiającej modelowi zrozumienie powiązań pomiędzy słowami.

Przykładem użycia tej architektury do analizy tekstu jest artykuł :

LayoutLM: Pre-training of Text and Layout for Document Image Understanding

Yiheng Xu, Minghao Li, Lei Cui, Shaohan Huang, Furu Wei, Ming Zhou

Gdzie oprócz ślepego tłumaczenia słów, zaimplementowano analizę położenia tekstu co przy analizie oficjalnych dokumentów (np. faktury) może mieć kluczowe znaczenie. W przypadku poszukiwania pieczęci algorytm mógłby nauczyć się powiązywać pieczętkę z tekstem "data i podpis" czy też powiązywać nazwę firmy z napisami na pieczęci.

Zalety:

- mechanizm self-attention umożliwiający rozumienie kontekstu w jakim występują słowa i łącznie informacji "rozrzuconych" po tekście
- wysoka precyzja
- równoległość obliczeń (szybsze trenowanie modelu)
- możliwość wytrenowania ogólnego modelu na dużym zbiorze danych i dostosowania do specyficznych potrzeb

Wady:

- Bardzo duże wymagania sprzętowe
- kwadratowa złożoność obliczeniowa, ograniczająca maksymalny rozmiar analizowanego tekstu

2.2. Segmentacja semantyczna - metoda polega na klasyfikacji każdego pojedynczego piksela na obrazie i przypisania go do odpowiedniej kategorii. Metoda polega najpierw na "streszczeniu" obrazu i wyciągnięciu z niego ogólnych zarysów "obiektów" i późniejszym przypisaniu już konkretnych pikseli do tych obiektów. Umożliwia to bardzo precyzyjne wyznaczanie granic obiektów rozpoznanych na obrazie.

Przykładem użycia segmentacji semantycznej jest:

"U-Net: Convolutional Networks for Biomedical Image Segmentation"

Olaf Ronneberger, Philipp Fischer, Thomas Brox

Gdzie dzięki segmentacji semantycznej można było wyznaczyć dokładne granice między komórkami badanymi pod mikroskopem. W przypadku zastosowania tej metody do wyszukiwania pieczęci program z łatwością wyszukiwałby czerwoną lub niebieską pieczęć na tle białej kartki i czarnego tekstu.

Zalety:

- Dobra obsługa nieregularnych kształtów
- Precyzja na poziomie pojedynczego piksela
- Możliwość wykorzystania zależności pomiędzy wykrytymi obiektami (np. pieczęć nad wielokropkiem)

Wady:

- Trudne i pracochłonne utworzenie zbioru danych
- Wysokie wymagania obliczeniowe
- Niezbalansowanie klas może powodować ignorowanie obiektów niedoreprezentowanych

2.3. Sieci syjamskie - metoda polega na porównywaniu przez algorytm dwóch zestawów danych (referencyjnego i badanego) za pomocą co najmniej dwóch podsieci posiadających tę samą konfigurację przetwarzających dane w identyczny sposób. Wykrywanie obiektów polega na przetwarzaniu danych wejściowych na wektory i późniejszym porównaniu ich ze sobą stwierdzając czy są one tożsame czy różne.

Przykładem użycia tej metody do przetwarzania dokumentów jest artykuł:

"Siamese Neural Networks for One-shot Image Recognition"

Gregory'ego Kocha, Richarda Zemel, Ruslan Salakhutdinov

Gdzie autorzy zbudowali sieć neuronową złożoną z dwóch identycznych bliźniaczych podsieci i rozpoznawali obrazy badając na ile podobne są do siebie obraz referencyjny przetwarzany przez jedną sieć i obraz badany przetwarzany przez drugą. Zastosowanie tej metody do rozwiązania naszego problemu polegałoby na wgraniu bazy własnych pieczęci i poszukiwaniu ich na dokumencie.

Zalety:

- możliwość pracy na bardzo ograniczonym zbiorze danych
- odporność na niezbalansowane klasy
- brak konieczności ponownego trenowania

Wady:

- Czasochłonny trening
- Wolne wnioskowanie dla dużych baz danych
- Problemy z rozpoznawaniem słabo odbitych pieczęci

3. Opis wybranej koncepcji

Zastosowana metoda opiera się na wykorzystaniu nowoczesnej architektury głębokich sieci neuronowych do detekcji obiektów – YOLOv11 (You Only Look Once). Jest to najnowsza ewolucja jednej z najpopularniejszych rodzin modeli wizji komputerowej, która charakteryzuje się wyjątkową szybkością i precyzją, umożliwiając analizę obrazów w czasie rzeczywistym. W przesłanym projekcie wykorzystano konkretnie wariant YOLOv11n (Nano), który jest zoptymalizowany pod kątem niskiego zużycia zasobów przy zachowaniu wysokiej skuteczności wykrywania.

Głównym zadaniem algorytmu jest automatyczna identyfikacja i lokalizacja pieczętek na dokumentach cyfrowych - plikach PDF. Metoda ta odbiega od tradycyjnych technik przetwarzania obrazu opartych na prostym progowaniu czy analizie kolorów, które często zawodzą w przypadku pieczętek o słabej jakości, rozmytych lub nachodzących na tekst. YOLOv11 podchodzi do problemu jako do zadania regresji: sieć dzieli obraz na siatkę i dla każdego obszaru jednocześnie przewiduje prawdopodobieństwo wystąpienia obiektu oraz współrzędne jego ramki otaczającej (bounding box).

Proces wdrożenia metody obejmował kilka kluczowych etapów:

- Transfer Learning: Zamiast trenować sieć od zera, wykorzystano model wstępnie wytrenowany (yolo11n.pt). Dzięki temu algorytm posiada już bazową wiedzę o kształtach i teksturach, co pozwala na osiągnięcie wysokiej precyzji przy relatywnie niewielkim zbiorze danych specyficznych (pieczętek).
- Dostrajanie (Fine-tuning): Za pomocą skryptu train_model.py przeprowadzono proces uczenia na dedykowanym zbiorze „Stamps Dataset 2”. Podczas 100 epok model uczył się specyficznych cech wizualnych pieczętek: ich typowych kształtów (okrągłe, prostokątne), kolorystyki (zazwyczaj niebieskiej lub czerwonej) oraz faktu, że często są one naniesione na gęsty tekst dokumentu.
- Integracja hybrydowa: System został zaprojektowany tak, aby obsługiwać obecnie tylko czyste pliki PDF, lecz niewielkim nakładem pracy możliwa jest integracja innych typów danych jak JPG czy PNG. Dzięki modułowi pdf2image, algorytm konwertuje strony PDF na format rastrowy, co pozwala na aplikację modelu wizyjnego do dokumentacji biurowej.

Zastosowanie YOLOv11 gwarantuje, że system jest odporny na rotację pieczętek, ich różną wielkość oraz zakłócenia tła. Jest to podejście typu „end-to-end”, co oznacza, że jeden model neuronowy zajmuje się zarówno ekstrakcją cech, jak i ostateczną klasyfikacją, co minimalizuje błędy wynikające z ręcznego projektowania filtrów obrazu.

Dane wejściowe i wyjściowe

System akceptuje dane w dwóch głównych formach. Po pierwsze, są to pliki graficzne w formatach JPG, JPEG oraz PNG. Po drugie, system posiada zaawansowaną obsługę plików PDF (maksymalny rozmiar do 50MB zgodnie z konfiguracją w main.py). Użytkownik przesyła pliki za pośrednictwem formularza HTML w przeglądarce, co jest obsługiwane przez endpoint /api/upload. Obrazy mogą mieć dowolną rozdzielczość, jednak przed przetworzeniem przez model YOLO są one wewnętrznie skalowane do formatu akceptowanego przez sieć (640x640 pikseli), przy zachowaniu proporcji oryginału.

Wyjście algorytmu jest ustrukturyzowane i wielowarstwowe. Głównym produktem jest obiekt JSON przesyłany przez API, który zawiera:

- Statystyki zbiorcze (całkowita liczba wykrytych pieczętek).
- Szczegółową listę detekcji, gdzie dla każdej pieczętki podana jest nazwa klasy (stamp), współrzędne ramki otaczającej [x, y, w, h] oraz wskaźnik ufności (confidence score) wyrażony w ułamku (np. 0.95).
- Pliki PDF są pogrupowane według numerów stron.
- Dodatkowo system generuje obraz wynikowy (zapisywany w folderze results/), na którym naniesione są wizualne ramki oraz etykiety potwierdzające lokalizację pieczętek.

Forma i charakter wyjścia algorytmu

Wyjście ma charakter dualny. Programistycznie jest to ustrukturyzowany format JSON, który zawiera precyzyjne metadane o lokalizacji pieczętek na każdej stronie. Użytkowo system zwraca interaktywny podgląd w przeglądarce, gdzie na oryginalnym dokumencie wyświetlane są kolorowe ramki z opisem klasy i pewnością predykcji. Taka forma pozwala zarówno na szybką weryfikację przez człowieka, jak i bezproblemową komunikację między frontendem a backendem.

Mechanizm działania i realizacja w rzeczywistości

Algorytm wykonuje splotowe operacje matematyczne na obrazie, aktywując neurony rozpoznające kształt pieczętki. W rzeczywistości system działa jako aplikacja webowa. Użytkownik łąduje plik przez interfejs HTML/React, a serwer z akceleratorem (CPU/GPU) wykonuje wnioskowanie. Do wdrożenia niezbędne jest środowisko Python z biblioteką ultralytics, Poppler do obsługi PDF oraz serwer Flask zapewniający komunikację przez REST API. Dzięki konteneryzacji, system można łatwo przenieść na dowolny serwer produkcyjny.

Procedura testowania

Testowanie odbywa się poprzez skrypt stamp_detector.py, który uruchamia model na obrazach testowych i plikach PDF. Skuteczność mierzona jest precyzją (Precision) i pełnością (Recall) na zbiorze walidacyjnym. Dodatkowo, testy interfejsu sprawdzają poprawność przesyłu plików przez formularz HTML i poprawność generowanych odpowiedzi JSON.

Wyzwania integracyjne i mechanizm wizualizacji

Największym wyzwaniem projektowym było zapewnienie wydajnej komunikacji między backendem w Pythonie a nowoczesnym frontendem. Rozwiązano to poprzez budowę REST API, które przesyła pliki przez formularz HTML (multipart/form-data), a wyniki zwraca w ustrukturyzowanym formacie JSON. Aby umożliwić wymianę danych między różnymi portami lokalnymi, wdrożono politykę CORS.

Zaznaczanie pieczętek na dokumencie zrealizowano dwutorowo: backend wykorzystuje bibliotekę OpenCV do fizycznego narysowania ramek (bounding boxes) na obrazie wynikowym, który jest zapisywany w folderze /results. Jednocześnie frontend odbiera współrzędne z pliku JSON, co pozwala na dynamiczne wyświetlanie metadanych i interaktywny podgląd wykrytych obiektów bezpośrednio w przeglądarce użytkownika.